

**SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
VARAŽDIN**

Nina Krsnik

**VIŠEAGENTNA SIMULACIJA DINAMIKE
POPULACIJA U EKOSUSTAVU
GRABEŽLJIVAC - PLIJEN**

PROJEKT

VIŠEAGENTNI SUSTAVI

Varaždin, 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
V A R A Ž D I N

Nina Krsnik

Matični broj: 0016155048

Studij: Baze podataka i baze znanja

**VIŠEAGENTNA SIMULACIJA DINAMIKE POPULACIJA U
EKOSUSTAVU GRABEŽLJIVAC - PLIJEN**

PROJEKT

Mentor:

Prof. dr. sc. Markus Schatten

Varaždin, siječanj 2026.

Nina Krsnik

Izjava o izvornosti

Izjavljujem da je ovaj projekt izvorni rezultat mojeg rada te da se u izradi istoga nisam koristio drugim izvorima osim onima koji su u njemu navedeni. Za izradu rada su korištene etički prikladne i prihvatljive metode i tehnike rada.

Autorica potvrdila prihvatanjem odredbi u sustavu FOI Radovi

Sažetak

Ovaj seminarski rad bavi se razvojem višeagentne simulacije dinamike populacija u ekosustavu grabežljivac–plijen, gdje pojedinačne jedinke plijena (Plijen) i grabežljivaca (Predator) djeluju kao reaktivni agenti modelirani konačnim automatima u prostorno podijeljenom staništu s koordinatama x, y . Simulacija omogućuje istraživanje alternativnih fenomena poput oscilacija populacija i rizika izumiranja vrsta pod utjecajem parametara poput vremenskih uvjeta (sunny, cloudy, rainy, storm), faktora regeneracije resursa (weatherfactor), vjerojatnosti migracije (moveprob) i uspjeha predacije (predationsuccessprob). Implementirana je u Pythonu koristeći SPADE framework za diskretno-vremensku simulaciju na 2D prostoru, pri čemu agenti autonomno donose odluke o akcijama (feed, hunt, search, reproduce, rest, move) na temelju lokalnih informacija o energiji, dobi, statusu (alive) i okolini. Ovaj rad opisuje formalizam sustava kroz konačne automate agenata, strukturu staništa i stohastičke protokole interakcije, te analizira praktičnu primjenjivost za proučavanje utjecaja vremenskih uvjeta i resursa na stabilnost ekosustava kroz vizualizaciju energije i populacije iz CSV loga. Cilj rada je demonstrirati kako višeagentni pristup reproducira klasične ekološke modele tipa Lotka–Volterra uz dodavanje prostornih efekata, individualnog ponašanja agenata i dinamičkih okolišnih faktora.

Ključne riječi: višeagentni sustavi, predator-plijen simulacija, SPADE framework, konačni automati, populacijska dinamika, ekosustav modeliranje, stohastička simulacija, Python, Lotka-Volterra, resursi regeneracija

Sadržaj

1. Uvod	1
2. Glavni dio teme	2
2.1. Formalizam višeagentnog sustava	3
2.2. Reaktivni agenti kao konačni automati	3
2.3. Model okoliša i fragmentacije staništa	4
2.3.1. Stohastički procesi u modelu	4
2.3.2. Uloga Coach i Ekosustav agenata	5
2.4. Veza s Lotka–Volterra modelom	5
3. Opis implementacije višeagentnog sustava	7
3.1. SPADE Multi-Agent arhitektura	7
3.2. Okoliš i globalni parametri	7
3.3. Ponašanje Plijen agenta	8
3.4. Ponašanje Predator agenta	8
3.5. Logiranje i analiza (Coach agent)	8
3.6. Glavna simulacijska skripta	9
4. Prikaz rada aplikacije	10
5. Kritički osvrt	16
6. Zaključak	17
7. Literatura	18

1. Uvod

Uvod ovog seminarskog rada bavi se razvojem višeagentne simulacije dinamike populacija u ekosustavu grabežljivac–plijen, kao napredne alternative klasičnim modelima temeljenima na diferencijalnim jednadžbama tipa Lotka–Volterra. Takvi modeli dugo su bili standard u teorijskoj ekologiji, ali ne uzimaju u obzir individualno ponašanje organizama niti prostorne heterogenosti staništa definiranog koordinatama x, y . Višeagentni pristup omogućuje da svaka jedinka plijena (Plijen) i grabežljivca (Predator) autonomno reagira na lokalne uvjete, što otvara prostor za proučavanje emergentnih fenomena poput oscilacija populacija, lokalnih izumiranja i prostornog grupiranja jedinki pod utjecajem vremenskih uvjeta i resursa.

Modelirani sustav predstavlja diskretno-vremensku simulaciju na 2D prostoru, u kojoj pojedinačne jedinke plijena i grabežljivaca djeluju kao reaktivni agenti opisani konačnim automatima. Agenti autonomno donose odluke o akcijama (feed, hunt, search, reproduce, rest, move) na temelju lokalnih informacija o energiji, dobi, statusu (alive), resursima, prisutnosti drugih agenata te okolišnih faktora poput weatherfactor, moveprob i predationsuccessprob, dok stohastički protokoli uvode realizam u dinamiku interakcija.

Implementacija uključuje formalni opis višeagentnog sustava preko konačnih automata agenata, strukture staništa i stohastičkih protokola interakcija realiziranih u Pythonu koristeći SPADE framework, uz analizu rezultata kroz CSV logove i vizualizaciju energije te populacije. Rezultati simulacije uspoređuju se s klasičnim Lotka–Volterra modelom te analiziraju kako promjene parametara poput regeneracije resursa i intenziteta predacije utječu na stabilnost populacija i rizik izumiranja vrsta, pri čemu se dobivaju obrasci dinamike koji kombiniraju poznate teorijske predikcije s prostornim efektima i individualnim ponašanjem agenata.

Cilj rada je izraditi i opisati višeagentnu simulaciju koja na razumljiv način povezuje teorijske koncepte reaktivnih agenata, prostornog modeliranja s koordinatama x, y i ekološke dinamike te omogućuje eksperimentiranje s različitim scenarijima regeneracije resursa, ponašajnih strategija jedinki i promjene vremenskih uvjeta. Poseban naglasak stavlja se na jasnoću implementacije u Pythonu koristeći SPADE framework, usporedbu dobivenih rezultata s klasičnim modelima grabežljivca–plijena te na prikaz mogućnosti koje višeagentni pristup nudi za analizu oscilacija populacija i rizika izumiranja kroz vizualizaciju CSV logova.

Motivacija za odabir ove teme proizlazi iz interesa za povezivanje teorijske ekologije i računalnog modeliranja. Višeagentni sustavi predstavljaju svojevrsan spoj ekoloških koncepta s računalnom znanosti jer omogućuju testiranje hipoteza u simulacijama koje modeliraju pojedinačne jedinke plijena i grabežljivaca, njihova stanja (energija, dob, alive) i interakcijske protokole poput hunt, feed i reproduce. Takav pristup je osobito relevantan za proučavanje utjecaja dinamičkih faktora poput weatherfactor, moveprob i predationsuccessprob na bioraznolikost i dugoročnu stabilnost ekosustava.

2. Glavni dio teme

Višeagentni sustavi predstavljaju računalne sustave sastavljene od većeg broja međusobno povezanih, ali autonomnih agenata koji djeluju u zajedničkom okruženju. U takvim sustavima inteligentno ponašanje ne proizlazi nužno iz jedne centralne komponente, nego iz koordiniranog djelovanja više jednostavnijih jedinica. [1] [2] Agent se općenito definira kao računalni entitet koji posjeduje sposobnost opažanja okoline kroz lokalne informacije (lokacija x,y, energija, dob), donošenja odluka na temelju trenutnog stanja i djelovanja na okolinu kroz skup dopuštenih akcija (feed, hunt, search, reproduce, rest, move). Zahvaljujući toj strukturi, višeagentni sustavi pogodni su za modeliranje složenih, dinamičkih i distribuiranih problema poput simulacija ekosustava grabežljivac–plijen. [3]

Jedno od ključnih obilježja agenata u višeagentnim sustavima jest autonomija. [1] Agenti sami upravljaju svojim ponašanjem bez stalnog izravnog nadzora, te raspolažu vlastitim stanjem (energija, dob, alive status) i strategijama odlučivanja ovisno o okolišnim faktorima poput vremena (sunny, cloudy, rainy, storm) i resursa. Osim autonomije, važna je reaktivnost, odnosno sposobnost pravovremenog odgovora na promjene u okolini (npr. prisutnost predatora/plijena ili promjena weatherfactor), dok proaktivnost podrazumijeva samoinicirane akcije poput reprodukcije ili migracije. [2]

Treća bitna karakteristika je socijalna sposobnost, odnosno mogućnost interakcija među agentima bez eksplicitne komunikacije porukama. U okviru višeagentne simulacije interakcije su natjecateljske (hunt/feed između Predator i Plijen) ili suradničke (reprodukcija unutar vrste), a stohastički protokoli (moveprob, predationsuccessprob) uvode realizam u dinamiku. Takve hibridne interakcije obogaćuju simulaciju ekosustava gdje se istodobno odvijaju predacija i razmnožavanje. [3]

Višeagentni sustavi u ovom projektu distribuirani su preko SPADE frameworka: obrada stanja i odluka raspodijeljena je na agente koji djeluju na zajedničkom 2D prostoru. Takva arhitektura povećava robusnost (jedan agent može umrijeti bez prekida simulacije) i olakšava skaliranje broja jedinki, a heterogenost se očituje u različitim ulogama Plijen i Predator agenata s različitim akcijama i parametrima. To omogućuje vjerno modeliranje ekosustava s resursima regeneracijom i vremenskim utjecajima.

Zbog svoje modularne prirode, višeagentni sustavi omogućuju razvoj simulacije na temelju kombiniranja agenata s jasno definiranim ponašanjem. Svaki agent (Plijen/Predator) razvija se samostalno, a cjelokupna dinamika (oscilacije populacija, rizik izumiranja) dobiva se kroz njihove interakcije, logirane u CSV datoteke za analizu i vizualizaciju. Ovakav pristup primjenjiv je u simulacijama bioloških sustava, gdje modelira emergentno ponašanje velikog broja jedinki pod utjecajem stohastičkih faktora. [4]

2.1. Formalizam višeagentnog sustava

Višeagentni sustav koji se modelira u ovom radu definira se kao trojka

$$MAS = (A, E, I),$$

gdje je A konačan skup agenata, E okoliš, a I skup protokola interakcije među agentima i s okolišem. [3]

U opisanom modelu skup agenata A čine jedinke četiri vrste: `Plijen`, `Predator`, `Ekosustav` i `Coach`, pri čemu su `Plijen` i `Predator` pojedinačne jedinke s vlastitim stanjem (x, y , energija, dob, alive), bazom lokalnih informacija i skupom dostupnih akcija `{feed, hunt, search, reproduce, rest, move}`; `Ekosustav` upravlja globalnim stanjem okoliša, regeneracijom resursa i vremenskim uvjetima; `Coach` koordinira simulaciju, logira podatke i analizira performanse.

Okoliš E je diskretan 2D prostor s koordinatama x, y na kojem agenti zauzimaju pozicije, konzumiraju resurse i podliježu utjecajima vremenskih uvjeta (`sunny`, `cloudy`, `rainy`, `storm`) koji modificiraju faktor regeneracije resursa (`weatherfactor`), upravljano od `Ekosustav` agenta.

Interakcije u sustavu odvijaju se na dvije razine. Na razini *neizravne interakcije* agenti utječu jedni na druge putem dijeljenog okoliša kojim upravlja `Ekosustav`, konzumacijom resursa, zauzimanjem prostora i promjenom lokalne gustoće populacija, logirano dnevno u CSV formatu od strane `Coach`-a.

Na razini *izravne interakcije* `Predator` i `Plijen` susreću se na istoj lokaciji (x, y), pri čemu dolazi do stohastičkog ishoda predacije determiniranog `predationsuccessprob`, gdje `Predator` dobiva energiju od uspješnog `hunt`-a, a `Plijen` gubi energiju ili mijenja status `alive=False`; komunikacija s `Coach`-om omogućuje praćenje i analizu.

U implementaciji SPADE agenti koriste implicitne i eksplicitne protokole interakcije (npr. poruke između `Coach`-a i drugih agenata), gdje se ponašanje koordinira kroz dijeljeno stanje okoliša upravljano `Ekosustav`-om i lokalna opažanja svakog agenta.

2.2. Reaktivni agenti kao konačni automati

Ponašanje svakog agenta modelira se kao reaktivni sustav opisan konačnim automatom. Konačni automat se formalno definira kao uređena petorka

$$A = (S, I, O, \delta, \lambda),$$

gdje je S konačan skup stanja, I skup ulaza (percepcija), O skup izlaza (akcija), $\delta: S \times I \rightarrow S$ prijelazna funkcija, a $\lambda: S \times I \rightarrow O$ izlazna funkcija. Takav formalizam prikladno odgovara reaktivnim agentima čije se stanje ažurira na temelju lokalnih informacija o energiji, dobi, lokaciji (x, y), statusu `alive` i okolišnim faktorima (`weatherfactor`, `resursi`). [4]

Plijen agent je modeliran automatom čija su stanja determinirana energijskim i dobničkim uvjetima, s akcijama

$$O = \{\text{feed}, \text{search}, \text{reproduce}, \text{rest}, \text{move}\}.$$

Prijelazna funkcija δ odlučuje o sljedećem stanju na temelju percepcije prisutnosti resursa ili predatora u blizini, dok izlazna funkcija λ provodi akciju poput konzumacije resursa (*feed*), razmnožavanja (*reproduce*) ili kretanja (*move*) ovisno o *moveprob* i lokalnim uvjetima.

Predator agent koristi sličan automat s akcijama

$$O = \{\text{hunt}, \text{search}, \text{reproduce}, \text{rest}, \text{move}\},$$

gdje prijelazi između stanja traženja (*search*), lovljenja (*hunt*) i odmora ovisno o energiji i prisutnosti plijena. Uspjeh predacije determinira se stohastički preko *predationsuccessprob*, pri čemu Predator dobiva energiju od uspješnog hunt-a, a Plijen gubi energiju ili mijenja status na *alive=False*.

Ekosustav agent upravlja globalnim parametrima (vremensko stanje, regeneracija resursa), dok Coach koordinira dnevno logiranje u CSV format za analizu populacijskih trendova.

2.3. Model okoliša i fragmentacije staništa

Okoliš je modeliran kao 2D prostor s koordinatama x, y (dimenzije iz simulacije $\sim 10 \times 10$ na osnovu CSV podataka), pri čemu svaka pozicija nosi resurse i parametre regeneracije. U svakom diskretnom vremenskom koraku (dnevni timestep), resursi se regeneriraju prema faktoru *weatherfactor* (*sunny*=1.02, *cloudy*=0.95, *rainy*=0.85, *storm*=0.75), što modificira baznu regeneraciju *resourceregen* (fiksno ~ 2 jedinice):

$$r_{t+1}(p) = \min(\text{MAX_RESOURCE}, r_t(p) + \text{resourceregen} \times \text{weatherfactor}).$$

Ovo uvodi stohastičnost i realističnost kroz promjenljivo vrijeme, utječući na hranjenje (*feed*) Plijen agenata.

Fragmentacija staništa implicitno se modelira ograničenim prostorom i dinamičkim uvjetima (vremenske oluje smanjuju *moveprob*), razdvajajući regije s različitom dostupnošću resursa i susretima agenata. Migracija (*move* akcija) koristi *moveprob* za veći radijus kretanja, premošćujući fragmente i utječući na distribuciju populacija, vidljivo u prostornim promjenama x, y kroz dane simulacije.

2.3.1. Stohastički procesi u modelu

Stohastički procesi čine temelj realizma u višeagentnoj simulaciji, uvodeći nepredvidivost u odluke agenata i dinamiku okoliša. U projektu su implementirana tri ključna stohastička parametra vidljiva u CSV logu: *moveprob*=0.5 determinira vjerojatnost da agent oda-

bere `move` akciju umjesto `rest` ili `search`, simulirajući prirodnu varijabilnost u ponašanju jedinki; `predationsuccessprob=0.7` determinira šanse uspjeha `hunt` akcije kada `Predator` i `Plijen` dijele istu (x, y) poziciju, gdje uspješan lov povećava energiju predatora dok neuspjeh može uzrokovati pad energije plijena ili gubitak `alive` statusa; `weatherfactor` pak varira između 1.02 (`sunny`), 0.95 (`cloudy`), 0.85 (`rainy`) i 0.75 (`storm`), modificirajući svakodnevnu regeneraciju resursa po formuli `resourceregen × weatherfactor`.

Ovi parametri zajedno stvaraju emergentne efekte poput lokalnih izumiranja tijekom olujnih razdoblja ili koncentracije agenata u regijama s visokim resursima, generirajući diskretnu aproksimaciju stohastičkog Lotka–Volterra modela:

$$\dot{x} = \alpha x(1 - p) - \beta xyq, \quad \dot{y} = \delta xyq - \gamma y,$$

gdje $p = \text{moveprob}$, $q = \text{predationsuccessprob}$.

2.3.2. Uloga Coach i Ekosustav agenata

Projekt implementira četiri SPADE agenta s hijerarhijskom podjelom odgovornosti: `Plijen` i `Predator` predstavljaju autonomne jedinice s individualnim stanjem (x, y pozicija, energija, `dob`, `alive` status) koje izvršavaju osnovne akcije (`feed`, `hunt`, `search`, `reproduce`, `rest`, `move`), dok `Ekosustav` i `Coach` obavlja sistemsku ulogu.

`Ekosustav` agent centralizirano upravlja globalnim okolišnim stanjem – svakodnevno ažurira `weatherfactor` prema stohastičkom vremenskom modelu, računa regeneraciju resursa na svim pozicijama i sinhronizira `resourceregen`, `moveprob` i `predationsuccessprob` parametre, osiguravajući konzistentnost okoline za sve jedinice.

`Coach` agent djeluje kao promatrač i analitičar: prikuplja stanja svih agenata na kraju svakog dana (`day`, `role`, `name`, x, y , `energy`, `age`, `alive`, `action`, `weatherfactor` itd.) u strukturirani CSV format (`ecosystem_history_.csv`), pokreće analizu populacijskih trendova i generira vizualizacije energije te broja živih jedinki putem `analyze.py` skriptnog alata s `pandas` i `matplotlib` bibliotekama.

Sistemske agente omogućuju hijerarhijsku kontrolu i observaciju bez narušavanja autonomije pojedinačnih `Plijen/Predator` agenata.

2.4. Veza s Lotka–Volterra modelom

Klasični Lotka–Volterra model opisuje dinamiku plijena $x(t)$ i predatora $y(t)$ sustavom diferencijalnih jednadžbi [5]

$$\dot{x} = \alpha x - \beta xy, \quad \dot{y} = \delta xy - \gamma y,$$

pri čemu se pretpostavlja homogeno okruženje, kontinuirano vrijeme i populacije opisane kao gustoće. Takav sustav pokazuje karakteristične cikličke oscilacije populacija: rast plijena po-

tiče rast predatora, povećana predacija smanjuje plijen, što zatim dovodi do pada predatora i ponovnog rasta plijena.

Višeagentni model korišten u ovom radu može se promatrati kao diskretna, agent-orijentirana aproksimacija klasične Lotka–Volterra dinamike, uz uvođenje dodatnih elemenata realizma. Umjesto rada s kontinuiranim gustoćama populacija, model se temelji na diskretnim agentima tipa `Plijen` i `Predator`, pri čemu svaki agent posjeduje vlastito stanje, uključujući energiju, dob, prostornu poziciju (x, y) i varijablu `alive`.

Resursi u okolišu modelirani su eksplicitno te se obnavljaju pod utjecajem parametra `weatherfactor`. Interakcije između agenata, poput predacije (`hunt`) i hranjenja (`feed`), odvijaju se stohastički i ovise o parametrima `predationsuccessprob` i `moveprob`, pri čemu do interakcije dolazi kada se agenti nađu na istoj lokaciji.

Uvođenjem dinamičkih vremenskih uvjeta (`sunny`, `cloudy`, `rainy`, `storm`) te prostorne raspodjele agenata postiže se veća heterogenost sustava, što klasični Lotka–Volterra model ne uzima u obzir. Unatoč tome, makroskopski obrasci oscilacija populacija, vidljivi u CSV zapisima i vizualizacijama generiranim skriptom `analyze.py`, kvalitativno su u skladu s Lotka–Volterra predikcijama, pokazujući faze rasta, pada i stabilizacije populacija pod utjecajem stohastičkih parametara.

3. Opis implementacije višeagentnog sustava

Implementacija višeagentnog sustava slijedi formalizam opisan u teorijskom dijelu te je realizirana u programskom jeziku Python koristeći SPADE framework kao skup četiri agenta: `Plijen`, `Predator`, `Ekosustav` i `Coach`. Sustav obuhvaća dvije osnovne populacije agenata: `Plijen` (pojedinačne jedinke plijena) i `Predator` (pojedinačne jedinke grabežljivaca), pri čemu svaka jedinka posjeduje individualno stanje (`x`, `y`, `energija`, `dob`, `alive`) i autonomno donosi odluke o akcijama.

Svi autonomni agenti nasljeđuju SPADE `Behaviour` strukturu, gdje se ponašanje definira kroz stanje agenta i skup dopuštenih akcija $O = \{\text{feed, hunt, search, reproduce, rest, move}\}$. `Plijen` agenti prioritetno izvršavaju `feed` (konzumacija resursa), `reproduce` (razmnožavanje kad energija/dob zadovoljavaju uvjete) i `move` (migracija prema `moveprob=0.5`), dok `Predator` agenti koriste `hunt` (predacija s `predationsuccessprob=0.7`), `search` (traženje plijena) i `rest` (odmor pri niskoj energiji).

Prijelazi između stanja i odabir akcija implementirani su u SPADE `on_tick` metodama pojedinačnih agenata, koje čine programsku realizaciju prijelazne funkcije δ i izlazne funkcije λ konačnih automata. `Ekosustav` agent upravlja globalnim parametrima regeneracije resursa i `weatherfactor` varijacijama, dok `Coach` agent koordinira dnevno logiranje svih stanja u CSV format za analizu i vizualizaciju putem `analyze.py` skripte.

3.1. SPADE Multi-Agent arhitektura

Implementacija višeagentnog sustava realizirana je u Pythonu koristeći SPADE framework kao distribuirani sustav četiri vrste agenata: `Plijen`, `Predator`, `Ekosustav` i `Coach`. Svaki agent nasljeđuje SPADE `Agent` klasu i definira specifična `Behaviour`-a koja implementiraju reaktivno ponašanje kroz `on_tick` metode. Agenti komuniciraju asinkrono putem SPADE poruka, dok se globalno stanje simulacije sinhronizira dnevno (diskretni timestep = 1 dan).

Individualni agenti (`Plijen`, `Predator`) upravljaju vlastitim stanjem (`x`, `y`, `energy`, `age`, `alive`) i autonomno biraju akcije iz skupa $\{\text{feed, hunt, search, reproduce, rest, move}\}$ na temelju lokalne percepcije i stohastičkih parametara `moveprob`, `predationsuccessprob`. `Ekosustav` agent centralno upravlja okolišem, dok `Coach` koordinira logiranje i analizu.

3.2. Okoliš i globalni parametri

`Ekosustav` agent implementira 2D prostor s koordinatama (x, y) i upravlja regeneracijom resursa prema:

$$r_{t+1}(p) = \min(\text{MAX_RESOURCE}, r_t(p) + \text{resourceregen} \times \text{weatherfactor}),$$

gdje `weatherfactor` ciklično varira: `sunny=1.02`, `cloudy=0.95`, `rainy=0.85`, `storm=0.75`. Globalni parametri `moveprob=0.5` i `predationsuccessprob=0.7` dostupni su svim agen-

tima putem dijeljene reference na `Ekosustav`.

3.3. Ponašanje Plijen agenta

`Plijen` agent u `on_tick` metodi evaluira lokalno stanje i bira akciju:

- `feed`: konzumira dostupne resurse na poziciji (x, y) , energija $\uparrow$
- `reproduce`: stvara `Plijen[child]` susjednoj poziciji kad `energy > threshold` $\wedge$ `age > maturity`
- `move`: pomiče se s vjerojatnošću `moveprob=0.5`
- `rest/search`: prioritetno kod niske energije

Prijelazi stanja determinirani su energijom i dobom: niska energija $\rightarrow$ `rest`, visoka energija + zrela dob $\rightarrow$ `reproduce`, prisutnost `Predator`-a na istoj poziciji $\rightarrow$ gubitak energije ili `alive=False`.

3.4. Ponašanje Predator agenta

`Predator` agent slično bira akcije prilagođene grabežljivcu:

- `hunt`: uspješan s `predationsuccessprob=0.7` kod susreta s `Plijen`, energija $\uparrow$
- `search`: skenira okolne pozicije tražeći `Plijen`
- `reproduce`: stvara `Predator[child]` kod visoke energije
- `move/rest`: migracija i oporavak

Predacija se događa automatski kod ko-lociranosti: `Predator` dobiva energiju, `Plijen` gubi `alive` status ili energiju.

3.5. Logiranje i analiza (Coach agent)

`Coach` agent implementira `OneShotBehaviour` koji dnevno prikuplja stanja svih agenta:

(`day`, `role`, `name`, `x`, `y`, `energy`, `age`, `alive`, `action`, `weather`, `weatherfactor`, `resourceregen`, `moveprob`, `predations`)

Podaci se spremaju u `ecosystem_history_YYYYMMDD_HHMMSS.csv`. Analiza se provodi `analyze.py` skriptom:

```
def plot_population_alive(df):
    alive_prej = df[df['role']=='prej'].groupby('day')['alive'].sum()
    alive_pred = df[df['role']=='predator'].groupby('day')['alive'].sum()
    # matplotlib vizualizacija populacija
```

3.6. Glavna simulacijska skripta


Cjelovita simulacija pokreće se glavnom skriptom koja:

1. Inicijalizira XMPP server i SPADE konekcije
2. Kreira Ekosustav → Coach → N Plijen → M Predator
3. Pokreće dnevni ciklus: Ekosustav.update() → agents.on_tick() → Coach.log()
4. Zaustavlja nakon T dana ili uvjeta izumiranja
5. Generira `analyze.py` grafove

Projekt sadrži kompletan kod: SPADE agente, CSV logove (`ecosystem_history_20260116_20221` analizu (`analyze.py`) i dokumentaciju, omogućujući reproducibilnost i daljnje eksperimentiranje s parametrima.

4. Prikaz rada aplikacije

Prilikom pokretanja programa iz terminala pokreće se grafičko sučelje koje prvo otvara skočni prozor s karticom za unos parametara simulacije. U tom se prozoru od korisnika traži unos početnog broja plijenova, početnog broja grabežljivaca, broj dana simulacije, brzina regeneracije resursa, vjerojatnost migracije plijenova i intenzitet predacije (p). Za lakšu upotrebu zadane su predložene vrijednosti, ali one se i mogu promijeniti.




Slika 1: Odabir parametara - skočni prozor

Nakon potvrde odabranih parametara pokreće se simulacija, a u terminalu se paralelno ispisuju koji SPADE agenti se pokreću.


```
PS C:\Users\krsni\Desktop\sistem - Copy> python gui.py
PreySPAgent startao kao plijen22@xmpp.jp, broj plijenova=5
PredatorSPAgent startao kao predator22@xmpp.jp, broj predatora=2
EcosystemAgent startao kao ekosustav2@xmpp.jp
EcoCoachAgent startao kao agent222@xmpp.jp
EcoCoach: simulacija završena.
```

Slika 2: Ispis pokrenutih SPADE agenata i kraja simulacije

Kada se izvođenje simulacije završi, u glavnom prozoru aplikacije mijenja se tekst plavog statusnog teksta u obavijest korisniku da je simulacija uspješno završena, da su rezultati spremni te je moguće otvoriti prikaz željenog dijagrama koji je prikazan svaki u zasebnom pod-prozoru.



Slika 3: Plavi tekst koji potvrđuje da je simulacija izvršena



Slika 4: Oscilacije populacija plijena i grabežljivaca


Graf na slici 4 prikazuje dinamiku populacija plijena (zelena linija) i grabežljivaca (crvena linija) tijekom 30-dnevnog razdoblja simulacije s parametrima regeneracija resursa=2.0, migracija=0.5, predacija=0.7. Populacija plijena pokazuje stabilan rast od početnih ~5 jedinki do ~45 jedinki, što odražava uspješnu reprodukciju vidljivu u CSV logovima kroz `reproduce` akcije u prvim danima simulacije.

Populacija grabežljivaca bilježi eksplozivan rast od dana 15. nakon čega broj jedinki

naglo raste s ~ 5 na preko 50, što se može pripisati visokoj uspješnosti predacije (`predationsuccessprob=0.7`) manifestiranoj kroz `hunt` i `search` akcije. Ovakav obrazac konzistentan je s teorijskim očekivanjima gdje početni rast plijena potiče eksponencijalni rast predatora.

Simulacija ne pokazuje klasične Lotka–Volterra oscilacije jer traje samo 30 dana bez zasićenja resursa ili izumiranja populacija. Međutim, brzi rast grabežljivaca nakon dana 25. upućuje na potencijalnu nestabilnost: projekcija pokazuje da bi iscrpljivanje resursa pod utjecajem ograničene regeneracije (`resourceregen × weatherfactor`) moglo dovesti do kolapsa plijena, nakon čega bi uslijedio pad populacije grabežljivaca.


Prosječni dnevni rast plijena iznosi $\sim 1.3x$, dok grabežljivci nakon dana 15. rastu $\sim 3x$, što je u skladu s postavljenim stohastičkim parametrima (`moveprob=0.5`, `predationsuccessprob=0.7`). Graf potvrđuje ispravnost implementacije SPADE multi-agent sustava i reproducibilnost ključnih ekoloških dinamika u diskretnom, prostorno eksplicitnom modelu.



Slika 5: Energija populacija kroz vrijeme


Na drugom grafu prikazana je prosječna energija populacija plijena (zelena linija) i grabežljivaca (crvena linija) za iste parametre simulacije (`regen=2.0`, `migracija=0.5`, `predacija=0.7`). Može se uočiti da energija plijena postupno opada od 5. do 15. dana, što upućuje na pojačani pritisak predacije i iscrpljivanje lokalnih resursa, nakon čega slijedi blagi oporavak zbog regeneracije hrane i smanjenja gustoće jedinki.

Energija grabežljivaca u prvom dijelu simulacije zaostaje za energijom plijena, ali nakon 20. dana naglo raste i doseže vrhunac oko 25. dana, kada populacija predatora već dominira prostorom. U završnoj fazi obje krivulje se približavaju, što sugerira da se sustav približava zasićenju: plijen još uvijek osigurava dovoljno hrane, ali daljnji rast broja grabežljivaca mogao bi dovesti do pada njihove energije i potencijalne destabilizacije ekosustava.



Slika 6: Raspodjela dobi jedinki


Treći graf prikazuje distribuciju dobi jedinki plijena (lijevi boxplot) i grabežljivaca (desni boxplot) na kraju 30-dnevnog razdoblja simulacije. Medijalna dob plijena iznosi oko 10 (narančasta linija), s kvartilnim rasponom 5-15, bez outliera, što ukazuje na heterogenu populaciju s dominantnim mladim jedinkama i izostankom stršila. Medijalna dob grabežljivca je 8, nešto manje od plijena. Kvartilni raspon kreće se od 3 do 13 dana. Kod grabežljivaca su uočeni outlieri, njih 4 koji su u raspodijeljeni u rasponu od 25 do 30 dana. Širi raspon dobi plijena sugerira na veću reproduktivnu aktivnost plijena, ali veći rizik izumiranja zbog mladih jedinki; grabežljivci su s druge strane stabilniji, ali manje dinamični.



Slika 7: Uvoz prethodnih CSV datoteka za prikaz usporedbe oscilacija plijenova

Analiza 4 provodi usporedbu oscilacija populacije plijena za različite parametre. Nakon svake izvršene simulacije kreira se CSV datoteka s podacima i ona se automatski sprema na

mjesto gdje je pohranjen glavni program na računalu. Korisnik pritiskom na gumb Učitaj CSV i dodaj u usporedbu otvara skočni prozor i odabire CSV datoteke koje želi učitati. Nakon odabira željenih CSV datoteke automatski se kreira dijagram s prikazom svih oscilacija plijenova.



Slika 8: Oscilacije populacije plijenova za različite postavke parametara

Na slici 8 možemo vidjeti učitane CSV datoteke koje zajedno prikazuju oscilaciju populacije plijenova. Svaka od ovih datoteke prikazuje simulaciju koja je provedena za 30 dana u kojima se pratilo kretanje plijenova i za koju su bili uzeti različiti parametri vjerojatnosti migracije plijena (m) i intenzitet predacije (p). Sve krivulje počinju od 5 plijena jer je tako postavljeno u početnom odabiru parametara. Veća migracija ($m=0.8$, zelena krivulja) uzrokuje brži početni rast jer plikijenovi češće traže hranu na novim mjestima, ali isto tako povećavaju si rizik od predacije što je vidljivo oko 15 dana gdje se događa nagli pad. Niža migracija ($m=0.3$, narančasto) održava stabilniju populaciju dulje gdje je vidljivo da se pad broja plijenova uočava tek nakon 20. dana. Najveći intenzitet predacije ($p=0.7$, narančasta krivulja) dovodi do najbržeg pada i najniže krajnje populacije. Niži $p=0.4$ omogućuje sporiji pad i bolji oporavak.

Simulacija	Analiza 1	Analiza 2	Analiza 3	Analiza 4	Podaci
CSV datoteka: ecosystem_history_20260117_132022.csv Brzina regeneracije resursa: 2.0 Vjerojatnost migracije plijena: 0.5 Intenzitet predacije: 0.7 Broj dana simulacije: 30 Plijen nije izumro tijekom simulacije. Grabežljivac nije izumro tijekom simulacije. Sustav pokazuje značajne oscilacije u zadnjih 10 dana.					

Slika 9: Prikaz podataka nakon provedene simulacije

Na slici 9 može se vidjeti prikaz glavnih podataka koji su sada spremljeni u CSV datoteku i naziv te datoteke. Vidljivi su uneseni podaci prije početka simulacije: Brzina regeneracije resursa, Vjerojatnost migracije plijena, Intenzitet predacije, Broj dana simulacije. Na kraju dan je zaključak u obliku rečenice je li plijen ili grabežljivac izumro za vrijeme simulacije te u kojim danima se prikazuje značajnija oscilacija.

5. Kritički osvrt

Ovaj seminarski projekt pokazuje kako se teorijski koncepti višeagentnih sustava mogu pretvoriti u radnu simulaciju ekosustava grabežljivac-plijen. Koristi SPADE framework u Pythonu gdje su reaktivni agenti modelirani kao konačni automati, s jasnom podjelom uloga između Plijen i Predator agenata te sistemskih agenata Ekosustav i Coach.

Model reproducira Lotka-Volterra dinamiku uz dodatak prostornih efekata i vremenskih uvjeta (sunny 1.02, storm 0.75). Praktična izvedivost je ostvarena modularnom SPADE arhitekturom koja omogućuje jednostavnu inicijalizaciju XMPP servera i GUI za unos parametara poput broja dana i regeneracije resursa. Dnevno logiranje u ecosystemhistory.csv čini simulaciju ponovljivom.

Kao edukativni alat, model je odličan za studente jer omogućuje eksperimentiranje s parametrima (npr. moveprob 0.5, predationsuccessprob 0.7) i istraživanje emergentnih pojava poput rizika izumiranja. Međutim, ograničenja poput malog 10x10 prostora i centraliziranog upravljanja Ekosustav/Coach agentima smanjuju distribuiranu autonomiju agenata.

Važno je naglasiti da parametri koji su korišteni u radu odabrani su za demonstraciju, ne za mapiranje stvarnih populacija, što ga čini demonstracijskim alatom.

Projekt otvara jasne smjerove proširenja: dodavanje kognitivnih agenata s učenjem, FIPA komunikacije za koordinaciju, ontološko modeliranje okoliša ili RL za evoluciju strategija. Ovo ga čini fleksibilnom bazom za daljnja studentska istraživanja bez umanjenja vrijednosti postojeće implementacije.

6. Zaključak

U projektu je razvijena višeagentna simulacija ekosustava grabežljivac-plijen koja spaja teorijske koncepte reaktivnih agenata s praktičnom Python/SPADE implementacijom. Modeliranjem Plijen i Predator agenata kao konačnih automata na 2D prostoru, uz sistemsku podršku Ekosustav i Coach agenata, postignuta je jasna reprodukcija Lotka-Volterra dinamike uz dodane prostorne i vremenske efekte.

Implementacija s GUI-jem za parametre, CSV logiranjem i matplotlib vizualizacijama pokazuje modularnost i reproducibilnost, idealnu za studentsko učenje multi-agentnih sustava. Rezultati potvrđuju kako lokalna ponašanja agenata (feed, hunt, reproduce) generiraju globalne obrasce rasta populacija i energijskih trendova.

Projekt ostvaruje postavljene ciljeve demonstracijom veze između formalnog opisa (stanja, prijelazi, akcije) i funkcionalnog koda, otvarajući put za daljnja studentska istraživanja. Simulacija reproducira ključne ekološke fenomene poput oscilacija populacija vidljivih u 30-dnevnim CSV zapisima. Korištenjem SPADE frameworka i stohastičkih parametara (moveprob 0.5, predationsuccessprob 0.7) modelira se realistična dinamika interakcija na lokalnoj razini.

U budućem radu simulaciju bi se moglo unaprijediti uvođenjem realističnijih parametara, dodatnih trofičkih razina, metoda učenja ili optimizacijom performansi, kao i integracijom s naprednijim alatima za analizu podataka. Inspirirano radom Yamada et al. (2020.), koji koristi multi-agent deep reinforcement learning (RL) za evoluciju predator-plijen ekosustava na velikoj skali, moglo bi se dodati mehanizme parenja i real-time evolucijski algoritam za poboljšanje fizičkih svojstava agenata poput brzine, napada i otpornosti. Takav razvoj bi omogućio adaptivno ponašanje agenata i emergentne osobine stvarnog svijeta, premašujući trenutne reaktivne limite modela.

7. Literatura

- 1 Wooldridge M. (2009.) *An Introduction to MultiAgent Systems*. 2nd ed. John Wiley & Sons. Preuzeto 6.1.2026. s <https://www.cs.ox.ac.uk/people/michael.wooldridge/pubs/imas/> [web:294]
- 2 Dorri A., Kanhere S. S., Jurdak R. (2018.) *Multi-Agent Systems: A Survey*. *IEEE Access*, vol. 6, str. 28573–28593. Preuzeto 6.1.2026. s <https://ieeexplore.ieee.org/document/8352646> [web:295]
- 3 Bousquet F., Le Page C. (2004.) “Multi-agent simulations and ecosystem management: a review.” *Ecological Modelling*, 176(3–4), 313–332. Preuzeto 6.1.2026. s <https://www.sciencedirect.com/science/article/pii/S0304380004000948> [web:279][web:292]
- 4 Yamada J., Shawe-Taylor J., Fountas Z. (2020.) “Evolution of a Complex Predator–Prey Ecosystem on Large-Scale Multi-Agent Reinforcement Learning.” arXiv preprint arXiv:2002.03267. Preuzeto 6.1.2026. s <https://arxiv.org/abs/2002.03267> [web:288][web:293]
- 5 G. Zhang, D. L. Allaire, D. A. McAdams, V. Shankar (2019.) System evolution prediction and manipulation using a Lotka–Volterra ecosystem model. *Design Studies*, vol. 60, pp. 103–138. Preuzeto 6.1.2026. s <https://www.sciencedirect.com/science/article/abs/pii/S0142694X18300711> [web:296]

Popis slika

1.	Odabir parametara - skočni prozor	10
2.	Ispis pokrenutih SPADE agenata i kraja simulacije	10
3.	Plavi tekst koji potvrđuje da je simulacija izvršena	11
4.	Oscilacije populacija plijena i grabežljivaca	11
5.	Energija populacija kroz vrijeme	12
6.	Raspodjela dobi jedinki	13
7.	Uvoz prethodnih CSV datoteka za prikaz usporedbe oscilacija plijenova	13
8.	Oscilacije populacije plijenova za različite postavke parametara	14
9.	Prikaz podataka nakon provedene simulacije	15